

**LAPORAN TEKNIS**  
**SISTEM REKOMENDASI FILM BERBASIS SEMANTIK SINOPSIS**  
**MENGGUNAKAN SENTENCE-BERT DAN TENSORFLOW**



**Disusun Oleh:**

Nabila Habwa Salsabila

CDCC180D6X2023

Deva Rahma Dwi P.

CDCC180D6X1031

**LEARNING PATH DATA SCIENCE**  
**CODING CAMP POWERED BY DBS FOUNDATION**  
**2026**

## DAFTAR ISI

|                                              |           |
|----------------------------------------------|-----------|
| <b>DAFTAR ISI.....</b>                       | <b>1</b>  |
| <b>Latar Belakang.....</b>                   | <b>2</b>  |
| <b>Problem Statement.....</b>                | <b>3</b>  |
| <b>Research Question.....</b>                | <b>3</b>  |
| <b>Tujuan.....</b>                           | <b>4</b>  |
| <b>Metodologi Data Science.....</b>          | <b>4</b>  |
| <b>Hasil.....</b>                            | <b>6</b>  |
| a. Data wrangling.....                       | 6         |
| b. Pertanyaan Bisnis.....                    | 8         |
| c. Explanatory Data Analysis (EDA).....      | 9         |
| d. Visualisasi dan Explanatory Analysis..... | 13        |
| e. Feature Engineering.....                  | 17        |
| f. Dashboard.....                            | 18        |
| g. A/B Testing.....                          | 22        |
| <b>Kesimpulan dan Saran.....</b>             | <b>23</b> |

## 1. Latar Belakang

Perkembangan industri hiburan digital telah menyebabkan meningkatnya jumlah film yang tersedia pada berbagai platform streaming. Kondisi ini memberikan banyak pilihan bagi pengguna, namun di sisi lain menimbulkan permasalahan *information overload*, yaitu kesulitan pengguna dalam menemukan film yang sesuai dengan preferensinya. Oleh karena itu, sistem rekomendasi menjadi komponen penting untuk membantu pengguna menemukan konten yang relevan secara lebih cepat dan efisien.

Namun demikian, sebagian besar sistem rekomendasi film yang ada saat ini masih mengandalkan pendekatan konvensional berbasis data seperti rating pengguna, genre, maupun riwayat tontonan. Pendekatan ini memiliki keterbatasan mendasar, yakni ketidakmampuannya dalam menangkap preferensi pengguna secara lebih dalam, terutama yang berkaitan dengan nuansa cerita, tema naratif, maupun atmosfer film. Akibatnya, dua film yang memiliki tema atau alur cerita serupa tetapi berada dalam kategori genre yang berbeda dapat dianggap tidak relevan oleh sistem. Selain itu, rekomendasi yang dihasilkan seringkali terasa kurang relevan dan kurang personal, khususnya bagi pengguna baru yang belum memiliki banyak riwayat interaksi (*cold-start problem*).

Salah satu sumber informasi yang kaya akan konteks dalam film adalah sinopsis. Sinopsis memuat ringkasan cerita, konflik, karakter, dan tema utama yang dapat menggambarkan isi film secara lebih mendalam dibandingkan atribut kategorikal seperti genre. Dengan memanfaatkan sinopsis, sistem rekomendasi dapat dibangun berdasarkan kemiripan makna (*semantic similarity*), sehingga rekomendasi yang dihasilkan tidak hanya bergantung pada kesamaan kategori, tetapi juga pada kedekatan konteks cerita.

Dalam beberapa tahun terakhir, perkembangan teknologi Natural Language Processing (NLP) memungkinkan representasi teks dilakukan secara lebih efektif melalui teknik *transfer learning*. Salah satu model yang banyak digunakan adalah Sentence-BERT (SBERT), yaitu pengembangan dari BERT yang dirancang untuk menghasilkan representasi kalimat dalam bentuk embedding semantik. Berbeda dengan metode representasi teks tradisional seperti Bag-of-Words atau TF-IDF yang berfokus pada frekuensi kata, Sentence-BERT mampu memahami hubungan makna antar kalimat sehingga lebih sesuai untuk tugas pengukuran kemiripan teks.

Pada proyek ini, pendekatan transfer learning diterapkan dengan memanfaatkan model Sentence-BERT untuk menghasilkan representasi semantik dari sinopsis film. Embedding yang dihasilkan kemudian diproses lebih lanjut menggunakan arsitektur autoencoder yang dibangun dengan TensorFlow Functional API untuk memperoleh representasi laten yang lebih ringkas dan informatif. Representasi tersebut selanjutnya digunakan dalam perhitungan *cosine similarity* untuk mengidentifikasi film-film yang memiliki kedekatan makna berdasarkan isi sinopsis. Dengan pendekatan ini, sistem diharapkan mampu memberikan rekomendasi yang lebih relevan dibandingkan metode yang hanya mengandalkan atribut kategorikal seperti genre atau rating.

Melalui penerapan Transfer Learning berbasis Sentence-BERT dan TensorFlow Functional API, diharapkan sistem rekomendasi yang dikembangkan mampu memberikan rekomendasi film yang lebih relevan, kontekstual, dan personal berdasarkan kemiripan semantik sinopsis. Dengan demikian, pengguna dapat menemukan film yang sesuai dengan minatnya tanpa harus bergantung sepenuhnya pada kategori atau popularitas film tersebut.

## **2. Problem Statement**

Berdasarkan latar belakang yang telah dijelaskan, permasalahan yang ingin diselesaikan dalam proyek ini adalah:

1. Sistem rekomendasi berbasis genre memiliki keterbatasan dalam memahami konteks dan makna cerita film.
2. Sinopsis film dapat digunakan sebagai sumber informasi untuk memahami isi film secara lebih mendalam, namun informasi tersebut belum dimanfaatkan secara optimal dalam proses rekomendasi.
3. Diperlukan pendekatan yang mampu merepresentasikan informasi semantik dari sinopsis film secara efektif sehingga dapat digunakan untuk menghasilkan rekomendasi yang lebih relevan.

## **3. Research Question**

Berdasarkan latar belakang yang telah dijelaskan, pertanyaan yang ingin dijawab dalam proyek ini sebagai berikut.

1. Bagaimana perbandingan performa sistem rekomendasi film berbasis genre dan berbasis sinopsis dalam menghasilkan rekomendasi yang relevan berdasarkan kesamaan rating?
2. Apa karakteristik utama sinopsis film, seperti kata dominan, frasa, panjang, dan kompleksitas teks, serta apakah karakteristik tersebut memiliki hubungan yang signifikan terhadap rating film?
3. Seberapa efektif dan stabil sistem rekomendasi berbasis sinopsis dalam menghasilkan rekomendasi yang relevan pada berbagai tingkat toleransi perbedaan rating?

#### 4. Tujuan

Berdasarkan perumusan masalah yang telah dirumuskan, tujuan yang ingin diselesaikan dalam proyek ini sebagai berikut.

1. Membandingkan performa sistem rekomendasi film berbasis genre dan berbasis sinopsis dalam menghasilkan rekomendasi yang relevan berdasarkan kesamaan rating.
2. Menganalisis karakteristik utama sinopsis film, seperti kata dominan, frasa, panjang, dan kompleksitas teks, serta hubungannya terhadap rating film.
3. Mengukur efektivitas dan stabilitas sistem rekomendasi berbasis sinopsis dalam menghasilkan rekomendasi yang relevan pada berbagai tingkat toleransi perbedaan rating.

#### 5. Metodologi Data Science

Pada proyek ini, dilakukan serangkaian tahapan Data Science secara end-to-end mulai dari pengumpulan data hingga deployment sistem rekomendasi. Seluruh tahapan dilakukan untuk membangun sistem rekomendasi film berbasis sinopsis menggunakan pendekatan *semantic similarity* dengan SEBRT dan *cosine similarity*.

1. Mengumpulkan dan menganalisis berbagai permasalahan pada sistem rekomendasi film, kemudian menentukan solusi utama yang akan dikembangkan dalam proyek.
2. Melakukan proses Data Wrangling secara *end-to-end*, yang mencakup:

- Gathering Data: Mengumpulkan dataset film dari Kaggle.
  - Assessing Data: Mengevaluasi kualitas, struktur, dan kondisi dataset.
  - Cleaning Data: Membersihkan dan mempersiapkan data sebelum masuk ke tahap analisis dan modeling.
3. Mendefinisikan pertanyaan bisnis yang dapat diukur berdasarkan permasalahan yang telah ditentukan.
  4. Melakukan Exploratory Data Analysis (EDA) untuk memperoleh insight dari dataset film, seperti distribusi rating, karakteristik sinopsis, panjang teks, kata dominan, dan hubungan antar variabel.
  5. Membuat visualisasi data dan melakukan explanatory analysis untuk membantu menjawab pertanyaan bisnis yang telah dirumuskan.
  6. Mengembangkan dashboard interaktif menggunakan Streamlit untuk menampilkan hasil analisis data dan visualisasi.
  7. Memastikan data telah siap diproses oleh model.
  8. Melakukan feature engineering untuk menghasilkan representasi fitur yang lebih informatif.
  9. Melakukan deployment dashboard ke Streamlit Cloud agar sistem rekomendasi dapat diakses secara publik.
  10. Melakukan evaluasi dan A/B testing dengan membandingkan performa sistem rekomendasi berbasis genre dan sistem rekomendasi berbasis sinopsis berdasarkan tingkat relevansi dan kesamaan rating film.
  11. Membuat laporan teknis secara komprehensif mulai dari tahap *problem discovery* hingga hasil akhir proyek.

## 6. Hasil

### a. Data wrangling

- Gathering data

```
# Load dataset
df = pd.read_csv("tmdb_5000_movies.csv")
df.head()
```

|   | budget    | genres                                                                                         | homepage                                     | id     | keywords                                                               | original_language | original_title                           | overview                                                                                                                                                                          | popularity | production_companies                                                                          | production                                                        |
|---|-----------|------------------------------------------------------------------------------------------------|----------------------------------------------|--------|------------------------------------------------------------------------|-------------------|------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------|-----------------------------------------------------------------------------------------------|-------------------------------------------------------------------|
| 0 | 237000000 | [{"id": 28, "name": "Action"}, {"id": 12, "name": "Adventure"}, {"id": 14, "name": "Fantasy"}] | http://www.avatarmovie.com/                  | 19995  | [{"id": 1463, "name": "culture clash"}, {"id": 726, "name": "Avatar"}] | en                | Avatar                                   | In the 22nd century, a paraplegic Marine is dispatched to the moon Pandora on a unique mission, but becomes torn between following orders and protecting an ancient civilization. | 150.437577 | [{"name": "Ingenious Film Partners", "id": 289}, {"name": "Twentieth Century Fox", "id": 1}], | [{"iso_3166_1": "US", "name": "Twentieth Century Fox", "id": 1}], |
| 1 | 300000000 | [{"id": 12, "name": "Adventure"}, {"id": 14, "name": "Fantasy"}]                               | http://disney.go.com/disneypictures/pirates/ | 285    | [{"id": 270, "name": "ocean"}, {"id": 726, "name": "Pirates"}]         | en                | Pirates of the Caribbean: At World's End | Captain Barbossa, long believed to be dead, has returned to the Caribbean Sea.                                                                                                    | 139.082615 | [{"name": "Walt Disney Pictures", "id": 2}, {"name": "Paramount Pictures", "id": 1}],         | [{"iso_3166_1": "US", "name": "Walt Disney Pictures", "id": 2}],  |
| 2 | 245000000 | [{"id": 28, "name": "Action"}, {"id": 12, "name": "Adventure"}, {"id": 14, "name": "Fantasy"}] | http://www.sonypictures.com/movies/spectre/  | 206647 | [{"id": 470, "name": "spy"}, {"id": 818, "name": "James Bond"}]        | en                | Spectre                                  | A cryptic message from Bond's past sends him on a new mission.                                                                                                                    | 107.376788 | [{"name": "Columbia Pictures", "id": 5}, {"name": "United Artists", "id": 1}],                | [{"iso_3166_1": "US", "name": "Columbia Pictures", "id": 5}],     |

Tahap data wrangling diawali dengan proses pengumpulan data dari Kaggle menggunakan dataset TMDb 5000 Movies yang dapat diakses melalui link berikut: <https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata>. Dataset tersebut terdiri atas 4.803 baris data film dan 20 fitur (kolom).

- Assessing data

|                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--|---|--------|---|--------|---|----------|------|----|---|----------|---|-------------------|---|----------------|---|----------|---|------------|---|----------------------|---|----------------------|---|--------------|---|---------|---|---------|---|------------------|---|--------|---|---------|-----|-------|---|--------------|---|------------|---|
| <pre>df.info()</pre> <pre>&lt;class 'pandas.core.frame.DataFrame'&gt; RangeIndex: 4803 entries, 0 to 4802 Data columns (total 20 columns):  #   Column              Non-Null Count  Dtype   ---  --  0   budget              4803 non-null  int64    1   genres              4803 non-null  object    2   homepage            1712 non-null  object    3   id                  4803 non-null  int64    4   keywords            4803 non-null  object    5   original_language   4803 non-null  object    6   original_title       4803 non-null  object    7   overview            4800 non-null  object    8   popularity           4803 non-null  float64   9   production_companies 4803 non-null  object   10   production_countries 4803 non-null  object   11   release_date        4802 non-null  object   12   revenue             4803 non-null  int64   13   runtime             4801 non-null  float64  14   spoken_languages    4803 non-null  object   15   status              4803 non-null  object   16   tagline             3959 non-null  object   17   title               4803 non-null  object   18   vote_average        4803 non-null  float64  19   vote_count          4803 non-null  int64   dtypes: float64(3), int64(4), object(13) memory usage: 750.6+ KB</pre> | <pre># Cek kolom kosong df.isnull().sum()</pre> <table><tr><td></td><td>0</td></tr><tr><td>budget</td><td>0</td></tr><tr><td>genres</td><td>0</td></tr><tr><td>homepage</td><td>3091</td></tr><tr><td>id</td><td>0</td></tr><tr><td>keywords</td><td>0</td></tr><tr><td>original_language</td><td>0</td></tr><tr><td>original_title</td><td>0</td></tr><tr><td>overview</td><td>3</td></tr><tr><td>popularity</td><td>0</td></tr><tr><td>production_companies</td><td>0</td></tr><tr><td>production_countries</td><td>0</td></tr><tr><td>release_date</td><td>1</td></tr><tr><td>revenue</td><td>0</td></tr><tr><td>runtime</td><td>2</td></tr><tr><td>spoken_languages</td><td>0</td></tr><tr><td>status</td><td>0</td></tr><tr><td>tagline</td><td>844</td></tr><tr><td>title</td><td>0</td></tr><tr><td>vote_average</td><td>0</td></tr><tr><td>vote_count</td><td>0</td></tr></table> <p>dtype: int64</p> |  | 0 | budget | 0 | genres | 0 | homepage | 3091 | id | 0 | keywords | 0 | original_language | 0 | original_title | 0 | overview | 3 | popularity | 0 | production_companies | 0 | production_countries | 0 | release_date | 1 | revenue | 0 | runtime | 2 | spoken_languages | 0 | status | 0 | tagline | 844 | title | 0 | vote_average | 0 | vote_count | 0 |
|                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| budget                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| genres                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| homepage                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       | 3091                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| id                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| keywords                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| original_language                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| original_title                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| overview                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       | 3                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| popularity                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| production_companies                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| production_countries                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| release_date                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   | 1                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| revenue                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| runtime                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        | 2                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| spoken_languages                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| status                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| tagline                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        | 844                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| title                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| vote_average                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |
| vote_count                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     | 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |  |   |        |   |        |   |          |      |    |   |          |   |                   |   |                |   |          |   |            |   |                      |   |                      |   |              |   |         |   |         |   |                  |   |        |   |         |     |       |   |              |   |            |   |

|               |              |               |             |              |             |              |              |
|---------------|--------------|---------------|-------------|--------------|-------------|--------------|--------------|
| df.describe() |              |               |             |              |             |              |              |
|               | budget       | id            | popularity  | revenue      | runtime     | vote_average | vote_count   |
| count         | 4.803000e+03 | 4803.000000   | 4803.000000 | 4.803000e+03 | 4801.000000 | 4803.000000  | 4803.000000  |
| mean          | 2.904504e+07 | 57165.484281  | 21.492301   | 8.226064e+07 | 106.875859  | 6.092172     | 690.217989   |
| std           | 4.072239e+07 | 88694.614033  | 31.816650   | 1.628571e+08 | 22.611935   | 1.194612     | 1234.585891  |
| min           | 0.000000e+00 | 5.000000      | 0.000000    | 0.000000e+00 | 0.000000    | 0.000000     | 0.000000     |
| 25%           | 7.900000e+05 | 9014.500000   | 4.668070    | 0.000000e+00 | 94.000000   | 5.600000     | 54.000000    |
| 50%           | 1.500000e+07 | 14629.000000  | 12.921594   | 1.917000e+07 | 103.000000  | 6.200000     | 235.000000   |
| 75%           | 4.000000e+07 | 58610.500000  | 28.313505   | 9.291719e+07 | 118.000000  | 6.800000     | 737.000000   |
| max           | 3.800000e+08 | 459488.000000 | 875.581305  | 2.787965e+09 | 338.000000  | 10.000000    | 13752.000000 |

```

# Cek berapa banyak duplikat data berdasarkan judul film
df.duplicated(subset=['title']).sum()

np.int64(3)

# Cek berapa banyak sinopsis yang kosong
df['overview'].isnull().sum()

np.int64(3)

```

Pada tahap assessing data, ditemukan beberapa permasalahan seperti 3091 pada kolom homepage, 3 nilai kosong pada kolom overview (sinopsis), 1 nilai kosong pada kolom release\_date, 844 nilai kosong pada kolom tagline, serta format data pada beberapa kolom yang masih berupa string JSON sehingga memerlukan proses ekstraksi dan penyesuaian tipe data. Selain itu, ditemukan karakter khusus, tanda baca, dan variasi penulisan huruf besar-kecil pada teks sinopsis yang perlu dinormalisasi sebelum analisis.

- Cleaning data

| <pre> def extract_names(column_data):     names = []     # Mengubah string menjadi list of dictionaries     for item in json.loads(column_data):         names.append(item['name'])     return names  df['genres'] = df['genres'].apply(extract_names) df['keywords'] = df['keywords'].apply(extract_names)  # Konversi Tanggal df['release_date'] = pd.to_datetime(df['release_date']) df['year'] = df['release_date'].dt.year  # Hapus baris yang tidak memiliki sinopsis df.dropna(subset=['overview'], inplace=True)  # Hapus baris duplikat berdasarkan judul df.drop_duplicates(subset=['title'], inplace=True)  # Menghapus spasi di setiap elemen list def collapse(L):     L1 = []     for i in L:         L1.append(i.replace(" ", ""))     return L1  # Menerapkan ke kolom genres dan keywords df['genres'] = df['genres'].apply(collapse) df['keywords'] = df['keywords'].apply(collapse) </pre> |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------|--|---|---------------------------------------------------|---|---------------------------------------------------|---|---------------------------------------------------|---|---------------------------------------------------|---|---------------------------------------------------|----------|--|---|---------------------------------------------------|---|---------------------------------------------------|---|---------------------------------------------------|---|---------------------------------------------------|---|---------------------------------------------------|
|                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               | <pre> def clean_text(text):     text = text.lower()     text = re.sub(r'[^a-z\s]', '', text)     return text  df['overview'] = df['overview'].apply(clean_text)  df[['overview']].head() </pre> <table> <tr> <th colspan="2">overview</th></tr> <tr> <td>0</td><td>in the nd century a paraplegic marine is dispa...</td></tr> <tr> <td>1</td><td>captain barbossa long believed to be dead has ...</td></tr> <tr> <td>2</td><td>a cryptic message from bonds past sends him on...</td></tr> <tr> <td>3</td><td>following the death of district attorney harve...</td></tr> <tr> <td>4</td><td>john carter is a warweary former military capt...</td></tr> </table><br><pre> def clean_text(text):     text = text.lower()     text = re.sub(r'[^a-z\s]', '', text)     return text  df['overview'] = df['overview'].apply(clean_text)  df[['overview']].head() </pre> <table> <tr> <th colspan="2">overview</th></tr> <tr> <td>0</td><td>in the nd century a paraplegic marine is dispa...</td></tr> <tr> <td>1</td><td>captain barbossa long believed to be dead has ...</td></tr> <tr> <td>2</td><td>a cryptic message from bonds past sends him on...</td></tr> <tr> <td>3</td><td>following the death of district attorney harve...</td></tr> <tr> <td>4</td><td>john carter is a warweary former military capt...</td></tr> </table> | overview |  | 0 | in the nd century a paraplegic marine is dispa... | 1 | captain barbossa long believed to be dead has ... | 2 | a cryptic message from bonds past sends him on... | 3 | following the death of district attorney harve... | 4 | john carter is a warweary former military capt... | overview |  | 0 | in the nd century a paraplegic marine is dispa... | 1 | captain barbossa long believed to be dead has ... | 2 | a cryptic message from bonds past sends him on... | 3 | following the death of district attorney harve... | 4 | john carter is a warweary former military capt... |
| overview                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | in the nd century a paraplegic marine is dispa...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 1                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | captain barbossa long believed to be dead has ...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 2                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | a cryptic message from bonds past sends him on...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 3                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | following the death of district attorney harve...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 4                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | john carter is a warweary former military capt...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| overview                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 0                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | in the nd century a paraplegic marine is dispa...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 1                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | captain barbossa long believed to be dead has ...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 2                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | a cryptic message from bonds past sends him on...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 3                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | following the death of district attorney harve...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |
| 4                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | john carter is a warweary former military capt...                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |          |  |   |                                                   |   |                                                   |   |                                                   |   |                                                   |   |                                                   |



```
def clean_genres(x):
    try:
        genres = ast.literal_eval(x)
        return [d['name'] for d in genres]
    except:
        return []

df['genres'] = df['genres'].apply(clean_genres)
df.head()
```

|   | budget    | genres | homepage                                     | id     | keywords                                           | original_language | original_title                           | overview                                          | popularity | production_companies                                                                       | release_date | revenue    | runtime | spoken_lang                         |
|---|-----------|--------|----------------------------------------------|--------|----------------------------------------------------|-------------------|------------------------------------------|---------------------------------------------------|------------|--------------------------------------------------------------------------------------------|--------------|------------|---------|-------------------------------------|
| 0 | 237000000 | []     | http://www.avatarmovie.com/                  | 19995  | [cultureclash, future, spacewar, spacecolony, ...] | en                | Avatar                                   | In the 22nd century, a paraplegic Marine is d...  | 150.437577 | [{"name": "Ingenious Film Partners", "id": "289..."}]                                      | 2009-12-10   | 2787965087 | 162.0   | [{"iso_639_1": "En", "name": "En"}] |
| 1 | 300000000 | []     | http://disney.go.com/disneypictures/pirates/ | 285    | [ocean, drugkase, eroticland, eastedatad...]       | en                | Pirates of the Caribbean: At World's End | Captain Barbossa, long believed to be dead, ha... | 139.082615 | [{"name": "Walt Disney Pictures", "id": "2"}, {"name": "Walt Disney Pictures", "id": "2"}] | 2007-05-19   | 961000000  | 169.0   | [{"iso_639_1": "En", "name": "En"}] |
| 2 | 245000000 | []     | http://www.sonypictures.com/movies/spectre/  | 206647 | [spy, basedonnovel, secondagent, sequel, mls, ...] | en                | Spectre                                  | A cryptic message from Bond's past sends him o... | 107.376788 | [{"name": "Columbia Pictures", "id": "5"}, {"name": "Columbia Pictures", "id": "5"}]       | 2015-10-26   | 880674609  | 148.0   | [{"iso_639_1": "En", "name": "En"}] |

Selanjutnya, dilakukan proses cleaning data yang mencakup penanganan nilai kosong, penghapusan data duplikat, normalisasi dan pembersihan teks sinopsis, serta konversi format data yang diperlukan. Hasil dari tahap ini adalah dataset yang lebih bersih, konsisten, dan siap digunakan untuk analisis lebih lanjut maupun pengembangan sistem rekomendasi.

#### b. Pertanyaan Bisnis

Berdasarkan proses identifikasi permasalahan, analisis data, dan pembangunan sistem rekomendasi film yang telah dilakukan, diperoleh beberapa pertanyaan bisnis yang digunakan sebagai dasar dalam proses analisis dan evaluasi sistem rekomendasi. Adapun pertanyaan bisnis yang diperoleh adalah sebagai berikut.

1. Bagaimana perbandingan performa sistem rekomendasi film berbasis genre dan berbasis sinopsis dalam menghasilkan rekomendasi yang relevan berdasarkan kesamaan rating?
2. Apa karakteristik utama sinopsis film, seperti kata dominan, frasa, panjang, dan kompleksitas teks, serta apakah karakteristik tersebut memiliki hubungan yang signifikan terhadap rating film?
3. Seberapa efektif dan stabil sistem rekomendasi berbasis sinopsis dalam menghasilkan rekomendasi yang relevan pada berbagai tingkat toleransi perbedaan rating?

c. Explanatory Data Analysis (EDA)

- Pertanyaan Bisnis 1

```
#Load dan membersihkan data
df=pd.read_csv("tmdb_5000.csv")

#Similarity sinopsis
tfidf = TfidfVectorizer(
    stop_words='english',
    max_features=5000
)

tfidf_matrix = tfidf.fit_transform(df['overview'])

print(tfidf_matrix.shape)

sinopsis_sim = cosine_similarity(tfidf_matrix, tfidf_matrix)

print(sinopsis_sim.shape)

#Similarity Genre
mlb = MultilabelBinarizer()
genre_matrix = mlb.fit_transform(df['genres'])

genre_sim = cosine_similarity(genre_matrix)

print(genre_matrix.shape)

#Metrix evaluasi
def relevance_tolerance(df, similarity_matrix, top_k=5, tolerance=1.0):
    hit = 0
    total = 0
```

```
    for i in range(len(df)):
        sim_scores = list(enumerate(similarity_matrix[i]))

        sim_scores = [x for x in sim_scores if x[0] != i]

        sim_scores = sorted(sim_scores, key=lambda x: x[1], reverse=True)[:top_k]

        original_rating = df.iloc[i]['vote_average']

        for idx, _ in sim_scores:
            rec_rating = df.iloc[idx]['vote_average']
            total += 1

            if abs(rec_rating - original_rating) <= tolerance:
                hit += 1

    return (hit / total) * 100

acc_genre = relevance_tolerance(df, genre_sim)
acc_sinopsis = relevance_tolerance(df, sinopsis_sim)

print("HASIL PERBANDINGAN")
print(f"Relevansi Genre      : {acc_genre:.2f}%")
print(f"Relevansi Sinopsis    : {acc_sinopsis:.2f}%")

(4797, 5000)
(4797, 4797)
(4797, 2)
HASIL PERBANDINGAN
Relevansi Genre      : 60.10%
Relevansi Sinopsis    : 58.18%
```

Berdasarkan hasil evaluasi dari tahap Exploratory Data Analysis (EDA) pada pertanyaan bisnis yang pertama, diperoleh sistem rekomendasi berbasis genre memperoleh tingkat relevansi sebesar 60.10%, sedangkan sistem berbasis sinopsis

memperoleh relevansi sebesar 58.18%. Hal ini menunjukkan bahwa sistem berbasis genre sedikit lebih baik dalam menghasilkan rekomendasi dengan rating yang mirip, sementara sistem berbasis sinopsis tetap mampu memberikan rekomendasi yang cukup relevan berdasarkan kemiripan konteks cerita.

- Pertanyaan Bisnis 2

```
df=pd.read_csv("tmdb_5000.csv")
df=df[['overview', 'vote_average']].dropna()

def clean_text(text):
    text=text.lower()
    text=re.sub(r'^a-z\s', '', text)
    return text

df['overview']=df['overview'].apply(clean_text)

#Top Kata Dominan
threshold = df['vote_average'].quantile(0.8)
top_movies = df[df['vote_average'] >= threshold]

vectorizer = TfidfVectorizer(stop_words='english', max_features=20)
X = vectorizer.fit_transform(top_movies['overview'])

word_freq = pd.DataFrame({
    'kata': vectorizer.get_feature_names_out(),
    'frekuensi': X.sum(axis=0).A1
}).sort_values(by='frekuensi', ascending=False)

print("\nTop Kata Dominan")
print(word_freq)

#Frase (Bigram)
from sklearn.feature_extraction.text import CountVectorizer
bigram=CountVectorizer(stop_words='english', ngram_range=(2,2), max_features=10)
X2=bigram.fit_transform(top_movies['overview'])

bigram_freq = pd.DataFrame({
    'frasa': bigram.get_feature_names_out(),
    'frekuensi': X2.sum(axis=0).A1}).sort_values(by='frekuensi', ascending=False).reset_index(drop=True)

print("\nTOP FRASA DOMINAN")
print(bigram_freq)

#Panjang Sinopsis
df['length'] = df['overview'].apply(lambda x: len(x.split()))

print("\nStatistik Panjang Sinopsis")
print(df['length'].describe())

#Kompleksitas (Jumlah kata unik)
df['unique_words']=df['overview'].apply(lambda x: len(set(x.split())))
print("\n Statistik Kompleksitas Sinopsis")
print(df['unique_words'].describe())

#Hubungan dengan rating
corr_length=df['length'].corr(df['vote_average'])
corr_complex=df['unique_words'].corr(df['vote_average'])

print("\n Korelasi")
print(f"Korelasi panjang vs rating : {corr_length:.3f}")
print(f"Korelasi kompleksitas Sinopsis vs rating: {corr_complex:.3f}")
```

| Top Kata Dominan |         |           | TOP FRASA DOMINAN                                |               |           |
|------------------|---------|-----------|--------------------------------------------------|---------------|-----------|
|                  | kata    | frekuensi |                                                  | frasa         | frekuensi |
| 7                | life    | 95.658303 | 0                                                | new york      | 37        |
| 13               | story   | 89.897636 | 1                                                | true story    | 30        |
| 19               | young   | 77.624717 | 2                                                | world war     | 29        |
| 11               | new     | 74.803946 | 3                                                | war ii        | 22        |
| 17               | world   | 73.341596 | 4                                                | tells story   | 19        |
| 10               | man     | 63.949424 | 5                                                | high school   | 19        |
| 9                | love    | 63.505245 | 6                                                | years later   | 15        |
| 0                | family  | 56.761476 | 7                                                | united states | 14        |
| 18               | years   | 54.103557 | 8                                                | falls love    | 13        |
| 5                | help    | 50.813645 | 9                                                | year old      | 13        |
| 15               | war     | 47.856750 | Statistik Panjang Sinopsis                       |               |           |
| 2                | film    | 45.762309 | count                                            | 4797.000000   |           |
| 16               | way     | 44.866100 | mean                                             | 51.782989     |           |
| 1                | father  | 41.436355 | std                                              | 27.648828     |           |
| 8                | lives   | 40.697427 | min                                              | 0.000000      |           |
| 3                | finds   | 40.243285 | 25%                                              | 30.000000     |           |
| 4                | friends | 38.981932 | 50%                                              | 48.000000     |           |
| 14               | time    | 38.310879 | 75%                                              | 66.000000     |           |
| 6                | home    | 36.772539 | max                                              | 175.000000    |           |
| 12               | son     | 33.149224 | Name: length, dtype: float64                     |               |           |
|                  |         |           | Statistik Kompleksitas Sinopsis                  |               |           |
|                  |         |           | count                                            | 4797.000000   |           |
|                  |         |           | mean                                             | 41.512612     |           |
|                  |         |           | std                                              | 18.761532     |           |
|                  |         |           | min                                              | 0.000000      |           |
|                  |         |           | 25%                                              | 27.000000     |           |
|                  |         |           | 50%                                              | 40.000000     |           |
|                  |         |           | 75%                                              | 53.000000     |           |
|                  |         |           | max                                              | 119.000000    |           |
|                  |         |           | Name: unique_words, dtype: float64               |               |           |
|                  |         |           | Korelasi                                         |               |           |
|                  |         |           | Korelasi panjang vs rating : -0.011              |               |           |
|                  |         |           | Korelasi kompleksitas Sinopsis vs rating: -0.009 |               |           |

Berdasarkan hasil evaluasi dari tahap Exploratory Data Analysis (EDA) pada pertanyaan bisnis yang kedua, diperoleh kata dominan yang sering muncul pada sinopsis film dengan rating tinggi antara lain life, story, young, world, dan love. Selain itu, frasa dominan seperti new york, true story, dan world war menunjukkan bahwa banyak film populer memiliki tema kehidupan, keluarga, dan sejarah. Hasil statistik menunjukkan bahwa rata-rata panjang sinopsis adalah sekitar 52 kata dengan rata-rata kompleksitas sebesar 42 kata unik. Namun, hasil korelasi menunjukkan bahwa panjang sinopsis maupun kompleksitas teks memiliki hubungan yang sangat lemah terhadap rating film, ditunjukkan oleh nilai korelasi yang mendekati nol.

- Pertanyaan Bisnis 3

```
#Menyembunyikan log transformers
logging.set_verbosity_error()

#Load data
df = pd.read_csv("tmdb_5000.csv")
df = df[['overview', 'vote_average']].dropna()

#Load model SBERT
model = SentenceTransformer('all-MiniLM-L6-v2')

#Embedding tanpa progress bar
embeddings = model.encode(
    df['overview'].tolist(),
    show_progress_bar=False
)

#Cosine similarity
similarity_matrix = cosine_similarity(
    embeddings,
    embeddings
)

#Fungsi evaluasi
def accuracy_rating_tolerance(
    df,
    similarity_matrix,
    top_k=5,
    tolerance=1.0
):
    hit = 0
    total = 0

    for i in range(len(df)):
```

```
        sim_scores = sorted(
            list(enumerate(similarity_matrix[i])),
            key=lambda x: x[1],
            reverse=True
        )[1:top_k+1]

        original_rating = df.iloc[i]['vote_average']

        for idx, _ in sim_scores:

            rec_rating = df.iloc[idx]['vote_average']
            total += 1

            if abs(rec_rating - original_rating) <= tolerance:
                hit += 1

        return (hit / total) * 100

#Hitung akurasi
accuracy = accuracy_rating_tolerance(
    df,
    similarity_matrix
)

print(f"Akurasi Top-5 (Tolerance ≤ 1 poin): {accuracy:.2f}%")
```

---

Loading weights: 100%  103/103 [00:00<00:00, 205.96it/s, Materializing param=pooler.dense.weight]  
 Akurasi Top-5 (Tolerance ≤ 1 poin): 59.79%


---

Berdasarkan hasil evaluasi dari tahap Exploratory Data Analysis (EDA) pada pertanyaan bisnis yang ketiga, diperoleh sistem rekomendasi sinopsis menggunakan SBERT dan cosine similarity memperoleh akurasi sebesar 59.79% pada Top-5 recommendation dengan toleransi selisih rating  $\leq 1$  poin. Hasil tersebut menunjukkan bahwa sistem mampu menghasilkan rekomendasi yang cukup relevan berdasarkan kemiripan sinopsis film. Dengan demikian, pendekatan semantic similarity menggunakan SBERT dapat membantu sistem dalam memahami konteks cerita film secara lebih baik dan menghasilkan rekomendasi yang cukup stabil berdasarkan kesamaan rating film.

d. Visualisasi dan Explanatory Analysis

Visualisasi data dikembangkan untuk mendukung proses analisis dan membantu menjawab setiap pertanyaan bisnis yang telah dirumuskan. Oleh karena itu, setiap pertanyaan bisnis direpresentasikan melalui visualisasi yang berbeda sesuai dengan tujuan analisisnya.

- Pertanyaan Bisnis 1



Untuk pertanyaan bisnis pertama, visualisasi berupa diagram batang digunakan untuk membandingkan performa sistem rekomendasi berbasis genre dan berbasis sinopsis pada berbagai rentang rating film. Hasil analisis menunjukkan bahwa sistem berbasis Genre mencapai relevansi 60.10%, sedikit mengungguli sistem berbasis Sinopsis yang berada di angka 58.21%. Perbedaan kinerja ini mengonfirmasi bahwa data terstruktur seperti genre berfungsi sebagai jangkar yang lebih stabil bagi algoritma cosine similarity. Dalam konteks preferensi pengguna, genre memberikan batasan tematik yang jelas, sehingga memudahkan

sistem untuk merekomendasikan film dengan profil kualitas yang serupa. Di sisi lain, metode sinopsis, meskipun sangat detail seringkali terjebak pada ambiguitas bahasa alami dan subjektivitas penulisan, yang membuat sistem terkadang menyarankan film dengan kemiripan naratif namun memiliki disparitas yang jauh.

- Pertanyaan Bisnis 2

```
#Memvisualisasikan Pertanyaan 2

#Top Kata
plt.figure()
plt.bar(word_freq['kata'], word_freq['frekuensi'])
plt.title("Top Kata Dominan (20% Film Terbaik)")
plt.xlabel("Kata")
plt.ylabel("Frekuensi")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()


#Top Frasa
plt.figure()
plt.bar(bigram_freq['frasa'], bigram_freq['frekuensi'])
plt.title("Top Frasa Dominan (Bigram)")
plt.xlabel("Frasa")
plt.ylabel("Frekuensi")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()

#Distribusi Panjang
df['length'] = df['overview'].apply(lambda x: len(x.split()))
plt.figure()
plt.hist(df['length'], bins=30)
plt.title("Distribusi Panjang Sinopsis")
plt.xlabel("Jumlah Kata")
plt.ylabel("Frekuensi")
plt.tight_layout()
plt.show()

#Distribusi Kompleksitas Sinopsis
df['unique_words'] = df['overview'].apply(lambda x: len(set(x.split())))
plt.figure()
plt.hist(df['unique_words'], bins=30)
plt.title("Distribusi Kompleksitas Sinopsis")
plt.xlabel("Jumlah Kata Unik")
plt.ylabel("Frekuensi")
plt.tight_layout()
plt.show()

#Panjang vs Rating
plt.figure()
plt.scatter(df['length'], df['vote_average'])
plt.title("Panjang Sinopsis vs Rating")
plt.xlabel("Panjang (Jumlah Kata)")
plt.ylabel("Rating")
plt.tight_layout()
plt.show()

#Kompleksitas Sinopsis vs Rating
plt.figure()
plt.scatter(df['unique_words'], df['vote_average'])
plt.title("Kompleksitas Sinopsis vs Rating")
plt.xlabel("Jumlah Kata Unik")
plt.ylabel("Rating")
plt.tight_layout()
plt.show()
```



Untuk pertanyaan bisnis kedua, digunakan beberapa visualisasi seperti diagram batang kata dominan, diagram batang frasa dominan (*bigram*), distribusi karakteristik teks, serta visualisasi hubungan antara karakteristik sinopsis dan rating film. Hasil analisis menunjukkan bahwa film-film dengan rating tinggi didominasi oleh tema-tema universal dan humanis yang tercermin kata-kata seperti *life*, *story*, *family*, dan *love*. Secara spesifik, frasa seperti *true story* dan *world war* muncul sebagai elemen naratif yang sering ditemukan pada film-film dengan apresiasi tinggi. Namun, temuan paling krusial muncul saat melakukan



pengujian korelasi statistik. Korelasi panjang sinopsis (-0.011) dan kompleksitas unik kosakata (-0.009) terhadap rating menunjukkan nilai yang hampir nol. Hal ini memberikan insight teknis yang penting. Kualitas sebuah film menurut audiens tidak ditentukan oleh panjang lebar deskripsi cerita, melainkan lebih dipengaruhi oleh eksekusi film itu sendiri.

- Pertanyaan Bisnis 3

```
#Visualisasi Pertanyaan Bisnis 3 (SBERT + Cosine Similarity)

tolerances = [0.5, 1.0, 1.5, 2.0]
accuracies = []

for tol in tolerances:
    acc = accuracy_rating_tolerance(
        df,
        similarity_matrix,
        tolerance=tol
    )
    accuracies.append(acc)

#Line Chart
plt.figure(figsize=(8,5))

plt.plot(
    tolerances,
    accuracies,
    marker='o'
)

plt.title("Akurasi Sistem Rekomendasi SBERT pada Berbagai Tolerance Rating")
plt.xlabel("Tolerance (Selisih Rating)")
plt.ylabel("Akurasi (%)")

for i in range(len(tolerances)):
    plt.text(
        tolerances[i],
        accuracies[i],
        f"{accuracies[i]:.2f}%",
        ha='center'
    )
```

```
plt.grid(True)
plt.show()


#Bar Chart untuk tolerance utama (<= 1 poin)
plt.figure(figsize=(6,5))

plt.bar(
    ['Top-5 Recommendation\n(Tolerance ≤ 1)'],
    [accuracy]
)

plt.title("Akurasi Sistem Rekomendasi Berbasis SBERT")
plt.ylabel("Akurasi (%)")

plt.text(
    0,
    accuracy,
    f"{accuracy:.2f}%",
    ha='center'
)

plt.show()
```



Untuk pertanyaan bisnis ketiga, digunakan grafik yang menunjukkan perubahan tingkat akurasi sistem pada berbagai nilai *tolerance*. Hasil analisis menunjukkan bahwa dengan tingkat akurasi 59.79% pada Top-5 rekomendasi dan toleransi selisih rating  $\leq 1$  poin, sistem menunjukkan performa yang sangat stabil dan reliabel. Angka ini memberikan indikasi kuat bahwa dalam setiap 5 film yang direkomendasikan sistem, lebih dari separuhnya berada dalam rentang kualitas yang dapat diterima oleh pengguna. Toleransi 1 poin adalah rentang yang sangat masuk akal dalam penilaian film (misalnya, pengguna yang menyukai film dengan rating 8.0 kemungkinan besar akan merasa puas dengan rekomendasi film ber-rating 7.0 hingga 9.0). Pencapaian angka 59.79% membuktikan bahwa sistem berbasis sinopsis berhasil menangkap "esensi kualitas" film yang serupa secara naratif, sekaligus memberikan hasil yang cukup relevan bagi preferensi audiens.

#### e. Feature Engineering

```

df = pd.read_csv("tmdb_5000.csv")
df = df[['overview', 'vote_average']].dropna()

#Load model SBERT
model = SentenceTransformer('all-MiniLM-L6-v2')

#Embedding tanpa progress bar
embeddings = model.encode(
    df['overview'].tolist(),
    show_progress_bar=False
)

#Cosine similarity
similarity_matrix = cosine_similarity(
    embeddings,
    embeddings
)

#Metrix evaluasi
def accuracy_rating_tolerance(
    df,
    similarity_matrix,
    top_k=5,
    tolerance=1.0
):
    hit = 0
    total = 0

    for i in range(len(df)):
        sim_scores = sorted(
            list(enumerate(similarity_matrix[i])),
            key=lambda x: x[1],
            reverse=True
        )[1:top_k+1]

```

Tahap feature engineering dilakukan untuk mengubah informasi pada sinopsis dan genre film menjadi representasi numerik yang dapat digunakan dalam proses analisis. Untuk sinopsis film, digunakan model Sentence-BERT (SBERT) yang mampu menghasilkan embedding semantik sehingga setiap sinopsis direpresentasikan dalam bentuk vektor numerik berdasarkan makna dan konteks kalimat. Representasi ini digunakan untuk menggambarkan kemiripan isi cerita antar film secara lebih kontekstual. Selain itu, informasi genre yang sebelumnya berbentuk kategori diubah menjadi representasi numerik menggunakan teknik MultiLabel Binarizer sehingga menghasilkan matriks fitur yang menunjukkan keberadaan masing-masing genre pada setiap film.

Berdasarkan representasi numerik yang telah terbentuk, dilakukan perhitungan cosine similarity untuk mengukur tingkat kemiripan antar film baik berdasarkan sinopsis maupun genre. Hasil perhitungan tersebut menghasilkan matriks kemiripan yang digunakan sebagai dasar dalam proses evaluasi sistem rekomendasi. Tahap ini menghasilkan dua jenis representasi fitur, yaitu fitur berbasis embedding sinopsis dan fitur berbasis genre, yang selanjutnya digunakan untuk membandingkan performa kedua pendekatan dalam menghasilkan rekomendasi film yang relevan.


f. Dashboard

Dashboard interaktif dikembangkan menggunakan Streamlit untuk mempermudah eksplorasi hasil analisis dan menjawab pertanyaan bisnis yang telah dirumuskan dan dapat diakses melalui link berikut:

<https://movie-recommendation-v3mpy94box2yktuugmhbj.streamlit.app/>


Berikut akan disajikan tampilan dashboard yang terdiri atas tiga halaman utama untuk merepresentasikan ketiga pertanyaan bisnis.


## 1. Perbandingan Performa: Genre vs Sinopsis



Halaman pertama digunakan untuk membandingkan performa sistem rekomendasi berbasis genre dan sistem rekomendasi berbasis sinopsis. Pengguna dapat mengatur rentang rating film menggunakan slider yang tersedia, kemudian dashboard akan menampilkan tingkat relevansi masing-masing pendekatan dalam bentuk diagram batang. Selain visualisasi perbandingan, dashboard juga akan menampilkan jumlah film yang termasuk dalam rentang rating yang dipilih serta ringkasan insight untuk membantu interpretasi hasil. Fitur ini memungkinkan pengguna melihat bagaimana performa kedua pendekatan berubah pada kelompok film dengan karakteristik rating yang berbeda.

## 2. Karakteristik Sinopsis & Hubungan Rating





Halaman kedua digunakan untuk mengeksplorasi karakteristik sinopsis film serta hubungannya dengan rating. Pengguna dapat memilih beberapa jenis analisa yang tersedia, yaitu: kata dominan (untuk menampilkan kata-kata paling sering muncul pada kelompok film tertentu), frasa/bigram (untuk menampilkan kombinasi dua kata yang paling sering muncul dalam sinopsis), distribusi teks (untuk melihat pola distribusi karakteristik sinopsis seperti panjang teks), dan hubungan rating (untuk menganalisis keterkaitan antara karakteristik sinopsis dengan rating film). Melalui fitur ini, pengguna dapat memperoleh pemahaman yang lebih mendalam mengenai pola bahasa yang muncul pada film dengan performa rating tertentu.

3. Efektabilitas & Stabilitas



Halaman ketiga digunakan untuk mengevaluasi efektivitas dan stabilitas sistem rekomendasi berbasis sinopsis. Pengguna dapat mengatur nilai toleransi menggunakan slider yang tersedia untuk melihat perubahan tingkat akurasi rekomendasi. Dashboard menampilkan grafik tren akurasi berdasarkan berbagai tingkat toleransi sehingga pengguna dapat mengamati bagaimana performa sistem berubah ketika batas perbedaan rating diperlonggar atau diperketat. Visualisasi ini membantu menunjukkan tingkat konsistensi sistem dalam menghasilkan rekomendasi yang relevan pada berbagai kondisi pengujian.

Secara keseluruhan, dashboard yang dikembangkan tidak hanya berfungsi sebagai media visualisasi data, tetapi juga sebagai alat eksplorasi interaktif yang membantu pengguna memahami hasil analisis, mengevaluasi performa sistem rekomendasi, serta mendukung proses pengambilan keputusan berbasis data.

#### g. A/B Testing

```
# Load full dataframe
df = pd.read_csv("tmdb_5000.csv")

# Sampel acak film untuk diuji
sample = df.sample(300, random_state=42)

# Hitung akurasi tiap sistem
results = {'A (Genre)': [], 'B (Sinopsis)': []}

for _, row in sample.iterrows():
    idx = df[df['title'] == row['title']].index[0]

    # Sistem A - Genre
    top_genre = sorted(enumerate(genre_sim[idx]),
                       key=lambda x: x[1], reverse=True)[1:6]
    hit_a = sum(1 for i, _ in top_genre
                if abs(df.iloc[i]['vote_average'] - row['vote_average']) <= 1.0)
    results['A (Genre)'].append(hit_a / 5)

    # Sistem B - Sinopsis
    top_sinopsis = sorted(enumerate(sinopsis_sim[idx]),
                          key=lambda x: x[1], reverse=True)[1:6]
    hit_b = sum(1 for i, _ in top_sinopsis
                if abs(df.iloc[i]['vote_average'] - row['vote_average']) <= 1.0)
    results['B (Sinopsis)'].append(hit_b / 5)

# Hasil
acc_a = np.mean(results['A (Genre)']) * 100
acc_b = np.mean(results['B (Sinopsis)']) * 100

print(f"Akurasi Sistem A (Genre) : {acc_a:.2f}%")
print(f"Akurasi Sistem B (Sinopsis): {acc_b:.2f}%")
print(f"Pemenang: {'Sinopsis' if acc_b > acc_a else 'Genre'})"

Akurasi Sistem A (Genre) : 67.47%
Akurasi Sistem B (Sinopsis): 61.27%
Pemenang: Genre
```

```

from scipy import stats

t_stat, p_value = stats.ttest_ind(results['A (Genre)'], results['B (Sinopsis)'])

print(f"\nt-statistic : {t_stat:.4f}")
print(f"p-value       : {p_value:.4f}")

if p_value < 0.05:
    print("Perbedaan signifikan secara statistik")
else:
    print("Perbedaan tidak signifikan secara statistik")

...
t-statistic : 2.8818
p-value      : 0.0041
Perbedaan signifikan secara statistik

```

Pengujian A/B Testing dilakukan dengan hipotesis nol ( $H_0$ ) bahwa tidak terdapat perbedaan performa yang signifikan antara sistem rekomendasi berbasis genre dan sistem rekomendasi berbasis sinopsis, serta hipotesis alternatif ( $H_1$ ) bahwa terdapat perbedaan performa yang signifikan antara kedua pendekatan tersebut. Hasil A/B testing menunjukkan bahwa sistem rekomendasi berbasis genre memperoleh akurasi sebesar 67,47%, sedangkan sistem rekomendasi berbasis sinopsis memperoleh akurasi sebesar 61,27%. Hasil uji statistik menggunakan independent t-test menghasilkan nilai p-value sebesar 0,0041, yang lebih kecil dari tingkat signifikansi 0,05. Dengan demikian, hipotesis nol ditolak dan terdapat perbedaan performa yang signifikan secara statistik antara kedua pendekatan.

Meskipun pendekatan berbasis genre menunjukkan performa yang lebih tinggi, pendekatan berbasis sinopsis tetap memiliki keunggulan dalam menangkap kemiripan isi dan nuansa cerita yang tidak selalu direpresentasikan oleh kategori genre. Hal ini menunjukkan bahwa informasi yang terkandung dalam sinopsis memiliki potensi untuk dimanfaatkan lebih lanjut dalam pengembangan sistem rekomendasi film yang lebih kontekstual.

## 7. Kesimpulan dan Saran

Berdasarkan hasil analisis mengenai pengembangan rekomendasi film yang telah dilakukan, diperoleh beberapa kesimpulan sebagai berikut.



1. Sistem rekomendasi berbasis genre memperoleh performa yang sedikit lebih baik dibandingkan sistem berbasis sinopsis dalam menghasilkan rekomendasi dengan rating yang mirip. Hasil evaluasi menunjukkan bahwa sistem berbasis genre memperoleh relevansi sebesar 60.10% sedangkan sistem berbasis sinopsis memperoleh relevansi sebesar 58.18%.
2. Analisis karakteristik sinopsis menunjukkan bahwa kata dominan seperti life, story, family, dan love sering muncul pada film dengan rating tinggi. Selain itu, frasa seperti true story dan world war juga banyak ditemukan pada film-film dengan apresiasi tinggi. Namun, panjang sinopsis dan kompleksitas teks memiliki hubungan yang sangat lemah terhadap rating film.
3. Sistem rekomendasi berbasis sinopsis menggunakan SBERT dan cosine similarity memperoleh akurasi sebesar 59.79% pada Top-5 recommendation dengan toleransi selisih rating  $\leq 1$  poin. Hasil tersebut menunjukkan bahwa pendekatan semantic similarity mampu menghasilkan rekomendasi yang cukup relevan berdasarkan kemiripan konteks cerita film.
4. Tahap feature engineering menggunakan SBERT berhasil mengubah sinopsis film menjadi representasi embedding semantik yang mampu merepresentasikan makna dan konteks kalimat secara lebih baik dibandingkan pendekatan berbasis frekuensi kata.
5. Hasil A/B testing menunjukkan bahwa terdapat perbedaan performa yang signifikan antara sistem rekomendasi berbasis genre dan sistem berbasis sinopsis dengan nilai p-value sebesar 0.0041. Meskipun sistem berbasis genre menunjukkan performa yang lebih tinggi, pendekatan berbasis sinopsis tetap memiliki keunggulan dalam menangkap kemiripan isi cerita dan nuansa naratif film.

Berdasarkan hasil yang diperoleh, pengembangan selanjutnya dapat dilakukan dengan menambahkan fitur lain seperti pemeran, sutradara, maupun kata kunci film untuk meningkatkan kualitas rekomendasi. Selain itu, evaluasi sistem juga dapat dikembangkan menggunakan metrik lain seperti precision, recall, atau NDCG agar pengukuran performa rekomendasi menjadi lebih komprehensif.